Inteligentni sistem za predikciju potražnje i optimizaciju zaliha

1. Naziv teme

Inteligentni sistem za predikciju potražnje i optimizaciju zaliha u maloprodaji

2. Definicija problema

U savremenoj maloprodaji i distributivnim sistemima donošenje odluka o nabavci i upravljanju zalihama predstavlja značajan izazov. Nepravilna procena buduće potražnje može dovesti do nestašice proizvoda, gubitka prodaje i nezadovoljstva kupaca, dok prevelike zalihe povećavaju troškove skladištenja i vezuju kapital.

Veliki broj kompanija i dalje se oslanja na ručne procene, iskustvo zaposlenih i jednostavne analize u tabelarnim alatima, što često dovodi do nepreciznih i nekonzistentnih odluka. Zbog toga postoji potreba za inteligentnim sistemima koji mogu automatski analizirati istorijske podatke i pružiti podršku prilikom planiranja nabavke i upravljanja zalihama.

Cilj ovog projekta je razvoj inteligentnog sistema za predikciju buduće prodaje proizvoda i optimizaciju zaliha na osnovu istorijskih podataka o prodaji. Sistem će koristiti metode mašinskog učenja za prognoziranje buduće potražnje, identifikaciju trendova i generisanje preporuka za upravljanje zalihama.

Pored same predikcije prodaje, sistem će omogućiti:

- identifikaciju rastućih i opadajućih trendova prodaje,
- procenu rizika od nestašice proizvoda,
- procenu rizika od viška zaliha,
- preporuku za dopunu zaliha,
- preporuku za smanjenje narednih narudžbina,
- vizuelizaciju rezultata i trendova.

Na ovaj način sistem pruža podršku donošenju poslovnih odluka i omogućava efikasnije upravljanje zalihama.

3. Skup podataka

Za realizaciju projekta koristi se javno dostupan skup podataka *Store Item Demand Forecasting Challenge* sa platforme Kaggle.

Skup sadrži sledeće atribute:

- date – datum prodaje
- store – identifikator prodavnice
- item – identifikator proizvoda
- sales – broj prodatih jedinica

Ciljno obeležje je atribut sales.

U implementaciji je omogućen rad i sa demo skupom podataka, koji se automatski generiše ukoliko originalni Kaggle skup nije dostupan. Demo skup simulira istoriju prodaje za više prodavnica i artikala i koristi se za testiranje kompletnog sistema.

Na osnovu osnovnih atributa generišu se dodatne karakteristike:

- dan u nedelji
- dan u mesecu
- nedelja u godini
- mesec
- kvartal
- godina
- sezona
- indikator vikenda
- lag atributi (*lag_1, lag_7, lag_14, lag_30*)
- rolling prosek prodaje za 7, 14 i 30 dana
- rolling standardna devijacija za 7, 14 i 30 dana
- dnevna i nedeljna razlika prodaje
- procentualna promena prodaje

4. Metodologija

I Eksplorativna analiza podataka (EDA)

Pre treniranja modela vrši se osnovna analiza podataka radi boljeg razumevanja strukture skupa i obrazaca prodaje.

Analiza obuhvata:

- broj zapisa i vremenski opseg podataka
- broj prodavnica i broj artikala
- prosečnu, minimalnu i maksimalnu prodaju
- ukupnu prodaju po prodavnicama
- ukupnu prodaju po proizvodima
- dnevnu i mesečnu agregaciju prodaje
- osnovnu korelacionu analizu između atributa i prodaje
- označavanje anomalno velikih vrednosti prodaje

Rezultati se čuvaju kao summary i pomoćne tabele koje se kasnije prikazuju u aplikaciji i izveštaju.

II Priprema podataka

U fazi pripreme podataka izvršava se:

- provera obaveznih kolona
- transformacija atributa datuma
- uklanjanje duplikata
- uklanjanje negativnih vrednosti prodaje
- označavanje anomalija pomoću IQR pravila
- generisanje dodatnih vremenskih atributa
- imputacija nedostajućih vrednosti u pipeline-u pomoću mediane
- standardizacija numeričkih atributa
- vremenska podela na trening i test skup

Napomena: Podela skupa nije slučajna, već vremenska, tako da model uči na starijim, a testira se na novijim podacima.

III Predikcija potražnje

Glavni problem modelovan je kao regresioni problem, gde je cilj predviđanje broja prodatih jedinica.

Implementirani i upoređeni modeli su:

- Linear Regression
- Ridge Regression
- KNN Regressor
- Random Forest Regressor
- Gradient Boosting Regressor
- MLP Regressor
- XGBoost Regressor (ukoliko je biblioteka dostupna)

Nakon treniranja modeli se evaluiraju i sortiraju prema performansama, a za dalje korišćenje bira se model sa najmanjom greškom, pre svega prema metrici RMSE.

IV Klasifikacija nivoa potražnje

Pored regresije, implementirana je i pomoćna klasifikacija nivoa potražnje.

Na osnovu vrednosti prodaje iz trening skupa formiraju se klase:

- low
- medium
- high

Klasifikacija se vrši modelom Gaussian Naive Bayes i koristi se kao dodatni sloj interpretacije rezultata i podrške poslovnim odlukama.

V Analiza zaliha

Na osnovu predviđene prodaje i istorijskih podataka sistem računa:

- prosečnu predviđenu dnevnu prodaju
- procenjeno trenutno stanje zaliha (*current_stock_proxy*)
- broj dana pokrivenosti zalihama
- sigurnosnu zalihu (*Safety Stock*)
- tačku ponovnog naručivanja (*Reorder Point*)
- preporučenu količinu za naručivanje

Dodatno se identifikuje trend prodaje kao:

- rastući trend
- opadajući trend
- stabilan trend

Takođe se primenjuje K-Means segmentacija stavki inventara radi grupisanja sličnih obrazaca ponašanja.

V. Sistem preporuka

Na osnovu poslovnih pravila sistem generiše preporuke kao što su:

- nema potrebe za dodatnim naručivanjem
- preporučuje se dopuna zaliha
- potrebno je hitno naručivanje
- postoji rizik od viška zaliha
- preporučuje se smanjenje narednih narudžbina

Pravila koriste pokazatelje kao što su:

- days_of_cover
- reorder_point
- predicted_daily_sales
- trend

VII Interpretacija modela

Za interpretaciju najboljeg modela koristi se analiza značaja atributa (*Feature Importance*), kada model to podržava. Na taj način se identifikuju karakteristike koje najviše doprinose predikciji prodaje.

VIII Vizuelizacija rezultata

Rezultati sistema prikazuju se kroz:

- istorijsku prodaju kroz vreme
- poređenje stvarne i predviđene prodaje
- pregled performansi modela
- značaj atributa
- pregled stanja zaliha i preporuka

Vizuelizacija je realizovana kroz Jupyter Notebook i Streamlit interfejs.

5. Način evaluacije

Regresioni modeli evaluiraju se pomoću metrika:

- MAE
- RMSE
- MAPE
- R^2 Score

Dodatna klasifikacija nivoa potražnje evaluira se pomoću:

- Accuracy
- Precision
- Recall
- F1 Weighted

Modeli se međusobno porede na test skupu dobijenom vremenskom podelom podataka.

Kao glavni kriterijum za izbor najboljeg regresionog modela koristi se RMSE.

6. Tehnologije

Za realizaciju projekta koriste se:

- Python
- pandas
- NumPy
- scikit-learn
- XGBoost
- matplotlib
- seaborn
- joblib
- Jupyter Notebook
- Streamlit

7. Očekivani rezultati

Očekuje se razvoj sistema koji:

- pouzdano predviđa prodaju proizvoda na osnovu istorijskih podataka
- poredi više modela mašinskog učenja i bira najbolji
- dodatno klasifikuje nivo potražnje
- generiše preporuke za upravljanje zalihama
- omogućava vizuelni pregled rezultata kroz notebook i aplikaciju

8. Relevantna literatura

- Scikit-learn Documentation – https://scikit-learn.org/
- Pandas Documentation – https://pandas.pydata.org/
- XGBoost Documentation – https://xgboost.readthedocs.io/
- LightGBM Documentation – https://lightgbm.readthedocs.io/
- Hyndman, R. J., Athanasopoulos, G. *Forecasting: Principles and Practice*
- Géron, A. *Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow*
- Brownlee, J. *Machine Learning Mastery with Python*
- Kaggle Store Item Demand Forecasting Challenge Dataset – https://www.kaggle.com/competitions/demand-forecasting-kernels-only/data